




下载APP



## 08 | 线性映射：如何从坐标系角度理解两个向量空间之间的函数？

2020-08-14 朱维刚

重学线性代数

[进入课程 >](#)**讲述：朱维刚**

时长 11:38 大小 10.67M



你好，我是朱维刚。欢迎你继续跟我学习线性代数，今天我们要讲的内容是“线性映射”。

前面我们学的内容都是局限在一个线性空间，或者说一个向量空间中，但今天不一样哦，我们要来看看两个向量空间之间的关系，也就是线性映射。

之前我说过，向量也是对象，是能够相加，能够被标量乘的对象，而且这样计算的结果还是向量。而**加和标量乘这样的运算同样适用线性映射**。比如：两个实数向量空间  $V$  和  $W$ ，有一个函数  $\phi$  来完成向量空间  $V$  到  $W$  的映射，如果我们想要同时保持向量空间结构不变，那么  $\phi$  就要满足：



$$\begin{aligned}\phi(x + y) &= \phi(x) + \phi(y) \\ \phi(\lambda x) &= \lambda\phi(x)\end{aligned}$$

其中，所有  $x$  和  $y$  属于向量空间  $V$ ， $\lambda$  属于实数。于是，我们得到了线性映射的定义。

## 线性映射定义

假设有两个向量空间  $V$  和  $W$ ， $\phi$  是一个函数，它完成了向量空间  $V$  到  $W$  的线性映射，那么线性映射必须满足等式：


$$\phi(\lambda x + \varphi y) = \lambda\phi(x) + \varphi\phi(y)$$

其中，任意  $x$  和  $y$  都属于向量空间  $V$ ，而任意  $\lambda$  和  $\varphi$  都属于实数。


当然，我们能把线性映射表示成矩阵，也就是线性映射矩阵，或者叫做变换矩阵。但因为向量还能组合成矩阵的列，所以我们要特别注意区分矩阵表示的是线性映射还是向量的集合。向量的集合是静态的，而变换矩阵则是动态的哦。

接下来我们再来看看两个任意集合  $V$  到  $W$  的三类特殊映射，了解一下函数  $\phi$  在不一样的情况下究竟表达了怎样的关系。


1. 函数  $\phi$  是单射 (Injective) 时：如果  $\phi(x) = \phi(y)$ ，那么  $x = y$ ，其中任意  $x$  和  $y$  都属于集合  $V$ ，从图中可以看出它表达的是一对一的关系，也就是我们可以由集合  $V$  的一个元素唯一确定一个集合  $W$  的元素。



2. 函数  $\phi$  是满射 ( Surjective ) : 也就是满足等式  $\phi(V) = W$  , 从图中我们可以看出它表达的是多对一的关系, 也就是多个集合  $V$  的元素能够确定一个集合  $W$  的元素。



3. 函数  $\phi$  是双射 (Bijjective)，就意味着它既是单射又是满射，从图中我们可以看出，它表达的是，所有  $V$  集合的元素都和  $W$  集合的元素一一对应，不多不少。




通过这些定义，我们就可以引入几个线性映射的特殊概念了。

1. 同构 (Isomorphism)：即函数  $\phi$  使  $V$  到  $W$  是线性且双射的；
2. 自同态 (Endomorphism)：即函数  $\phi$  使  $V$  到  $V$  是线性的；
3. 自同构 (Automorphism)：即函数  $\phi$  使  $V$  到  $V$  是线性且双射的；
4. 把  $V$  到  $V$ ，元素  $x$  到  $x$  的映射定义为恒等映射。

那么，为什么你需要了解这几个特殊的概念呢？那是因为我们通过这些概念引出一个定理：有限维度的向量空间  $V$  和  $W$ ，如果它们的维度相等，那么它们就是同构的。那就是说，同一维度的向量空间某种程度来说是一样的，因为它们能在没有发生损失的条件下互相转换。

比如， $\mathbb{R}^{m \times n}$  矩阵向量空间，和  $\mathbb{R}^{mn}$  长度是  $mn$  的向量空间，我们可以认为它们是相同的，因为它们维度都是  $mn$ ，而且存在一个线性映射和双射使得它们能互相转换。还记得在矩阵那节课中，我提到的矩阵转换吗？很多时候这类转换就是为了计算方便。



## 线性映射的矩阵表示


刚才提到了线性映射的矩阵表达，那在了解了线性映射的定义后，现在是时候来具体看一看这个更直观，且有实践意义的表达了。之所以说它有实践意义，那是因为我们赋予了它动态特性，让矩阵表示线性变换的过程。

如果存在一个  $n$  维向量空间  $V$  和它的一个有序基  $B = (b_1, \dots, b_n)$ ，那么对于任意一个属于  $V$  的  $x$ ，我们能得到一个这样的线性组合： $x = \alpha_1 b_1 + \dots + \alpha_n b_n$ ，我们可以说

$$\alpha = \begin{bmatrix} \alpha_1 \\ \cdot \\ \cdot \\ \cdot \\ \alpha_n \end{bmatrix}$$

是  $x$  的坐标向量或坐标表达。

我们都了解二维直角坐标系，现在我们通过一个例子，看看一个同样的向量在两个不同坐标系中的表示，加深一下你对线性映射的理解。



假设图中绿色是坐标系  $V$ ，黄色是坐标系  $W$ 。

在  $V$  中， $e_1$  和  $e_2$  是  $V$  的标准基，向量  $x$  由线性组合  $e_1$  和  $e_2$  表示， $x$  的坐标是  $(2,2)$ ，于是， $x$  在  $V$  中可以被表示成： $x = 2e_1 + 2e_2$ 。

在  $W$  中， $b_1$  和  $b_2$  是  $W$  的标准基，向量  $x$  由线性组合  $b_1$  和  $b_2$  表示，而这里的  $x$  坐标就不同了，变成了  $(1.09, 0.72)$ ，于是， $x$  在  $W$  中可以被表示成： $x = 1.09b_1 + 0.72b_2$ 。

说到这，你是不是对线性映射有了一个更直观的感受？现在我们就把矩阵引入到线性映射中，于是，我们就有了**变换矩阵**，也就是用矩阵表示线性变换的过程。

变换矩阵的定义是：我们有向量空间  $V$  和  $W$ ，它们各自有相应的有序基  $B = (b_1, \dots, b_n)$  和  $C = (c_1, \dots, c_m)$ ，而  $\phi$  就是  $V$  到  $W$  的线性映射： $\phi(b_j) = \alpha_{1j}c_1 + \dots + \alpha_{mj}c_m$ 。

线性映射  $\phi$  中的  $j$  是从 1 到  $n$ ，于是，我们就能得到一个  $\phi$  的  $m \times n$  的变换矩阵  $A_\phi$ ，这个变换矩阵中的元素是  $A_\phi(i, j) = \alpha_{ij}$ ，也就是说， $\phi(b_j)$  的坐标就是  $A_\phi$  的第  $j$  列。

我们可以来简化一下表达，把它表示成这样： $y = A_\phi(x)$ 。其中， $x$  是  $V$  基于  $B$  基的坐标向量， $y$  是  $W$  基于  $C$  基的坐标向量。所以，变换矩阵可以被用来在有序基上，映射坐标。


我们来看一个变换矩阵例子：已知两个向量空间  $V$  和  $W$ ，它们各自相应的有序基是  $B = (b_1, \dots, b_3)$  和  $C = (c_1, \dots, c_4)$ ，线性映射  $\phi$  表示成以下形式。

$$\begin{aligned}\phi(b_1) &= c_1 - c_2 + 3c_3 - c_4 \\ \phi(b_2) &= 2c_1 + c_2 + 7c_3 + 2c_4 \\ \phi(b_3) &= 3c_2 + c_3 + 4c_4\end{aligned}$$

于是，我们可以通过这些条件得到变换矩阵  $A_\phi$  如下。

$$A_\phi = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$

理解到这里还不算透彻，我们要更进一步，看看在现实图形图像处理中的线性变换是什么样的。接下来我们通过下面三个图形的例子来理解一下。



第一个图形是原始数据，你可以把它看成是由几百个向量的密集点组成的图。

第二个图形的效果看起来很简单，是由原始数据经过 45 度变换后得到的，它的变换矩阵是下面这样的。

$$A_1 = \begin{bmatrix} \cos\left(\frac{\pi}{4}\right) & -\sin\left(\frac{\pi}{4}\right) \\ \sin\left(\frac{\pi}{4}\right) & \cos\left(\frac{\pi}{4}\right) \end{bmatrix}$$

第三个图形是原始数据沿平行轴拉伸两倍的效果，变换矩阵是下面这样的。

$$A_2 = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$$

当然，这三个图形是比较简单的例子，是为了方便你理解，其实我们还能做更复杂的变换，比如：旋转、伸缩的组合等等。

## 基的改变

之前我们讨论的线性映射都是在**基**是一定的情况下，通过变换矩阵做线性映射。那如果基改变了呢？讨论基的改变在实践中也是有重要意义的。比如，为了最小化数据压缩损失，我们需要找到一个合适的被用来数据投影的基。



现在我们就来看看，如果我们改变向量空间  $V$  和  $W$  的基，线性映射  $\phi$  的变换矩阵会如何改变。我们给向量空间  $V$  和  $W$  各自增加两个有序基： $\tilde{B} = (\tilde{b}_1, \dots, \tilde{b}_n)$  和  $\tilde{C} = (\tilde{c}_1, \dots, \tilde{c}_m)$ ，而  $\tilde{A}_\phi$  是基于新的有序基的变换矩阵。这样， $\tilde{A}_\phi$  变换矩阵的计算公式就是： $\tilde{A}_\phi = T^{-1} A_\phi S$ 。

在这个新的公式中， $S$  是  $\mathbb{R}^{n \times n}$  向量空间  $V$  的恒等映射变换矩阵，向量空间  $V$  的恒等映射把基于  $\tilde{B}$  的坐标，映射到基于  $B$  的坐标上。同理， $T$  是  $\mathbb{R}^{m \times m}$  向量空间  $W$  的恒等映射变换矩阵，向量空间  $W$  的恒等映射把基于  $\tilde{C}$  的坐标，映射到基于  $C$  的坐标上。

理论是这样的，那我们还是要通过一个例子来看一下，基改变后，新的线性映射  $\phi$  的变换矩阵到底是如何获取的。我们已知，一个三维实数向量空间  $\mathbb{R}^3$  到四维实数向量空间  $\mathbb{R}^4$  的一个线性映射，它们各自有标准基  $B$  和  $C$ 。

$$B = \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right\}, C = \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix} \right\}$$

基于它们各自的标准基  $B$  和  $C$ ，它的变换矩阵是：

$$A_\phi = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$

那么现在，我们来看一下，基  $B$  和  $C$  改变为  $\tilde{B}$  和  $\tilde{C}$  之后，会有怎样的变化。

$$\tilde{B} = \left\{ \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} \right\}, \tilde{C} = \left\{ \begin{bmatrix} 1 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \end{bmatrix} \right\}$$

对于新基  $\tilde{B}$  和  $\tilde{C}$ ，我们得到  $S$  和  $T$ ：

$$S = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}, T = \begin{bmatrix} 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

于是，我们就可以通过公式得到想要的  $\tilde{A}_\phi$  了。

$$\tilde{A}_\phi = T^{-1} A_\phi S = \begin{bmatrix} -4 & -4 & -2 \\ 6 & 0 & 0 \\ 4 & 8 & 4 \\ 1 & 6 & 3 \end{bmatrix}$$

## 两个重要的子空间

最后，我再来讲两个重要的子空间——核空间和像空间，说它们重要是有原因的。核空间可以帮助我们研究线性方程组的性质，同时还可以帮助我们复杂问题简化，也就是将复杂的大集合分解成小集合的并来研究。而像空间可以帮助我们快速得到线性方程组的秩，这样就能快速判断线性方程组解的情况。现在我们来具体了解一下。


### 核空间

核空间也叫做零空间，你还记得  $Ax = b$  吗？核空间关注的就是  $Ax = 0$ ，也就是向量空间  $V$  中所有经过  $\phi$  映射为零的向量集合，用符号表示就是： $\ker(\phi)$ 。核的维数叫做零化度 (nullity)，表示成： $\dim(\ker(\phi))$ 。

### 像空间

向量空间  $V$  中所有经过  $\phi$  映射后的向量集合，叫做像空间，用符号表示就是： $\text{im}(\phi)$ ，像空间维数就是秩，表示成： $\text{rk}(\phi)$ 。

通过图形表达出来，你应该能够更好地理解。



最后我以一个定理来结束本节的内容，秩 - 零化度定理： $V$  的维数等于核空间维数与像空间维数之和  $\dim(V) = \dim(\ker(\phi)) + \text{rk}(\phi)$ 。

## 本节小结

好了，到这里线性映射这一讲就结束了，最后我再总结一下前面讲解的内容。

线性映射赋予了线性代数灵魂，也让它在计算机科学中发挥了很大的作用。线性映射的矩阵变换是这一节的重点，你要牢固掌握，因为它在无数现实场景中都在使用，比如：三维图形图像处理中的线性变换，图形的伸缩、旋转等等。

## 线性代数练习场

好，今天练习时刻到了，刚刚我们通过图形图像处理中的线性变换的例子，讲了矩阵变换。现在我们还是以这个例子为基础，不过这一次轮到你来解答问题了。如果我们把原始数据整体沿平行轴收缩两倍，那变换矩阵会是怎样的呢？

欢迎在留言区或者部落里晒出你的变换矩阵。如果你觉得有所收获，也欢迎你把这篇文章分享给你的朋友。

[提建议](#)

© 版权归极客邦科技所有，未经许可不得传播售卖。页面已增加防盗追踪，如有侵权极客邦将依法追究其法律责任。

上一篇 07 | 基和秩：为什么说它表达了向量空间中“有用”的向量个数？

下一篇 09 | 仿射空间：如何在图形的平移操作中大显身手？

## 精选留言 (1)

[写留言](#)

那一刻

2020-08-14

请教老师两个问题，

1. 在基改变情况下，通过变换矩阵做线性映射。 $A\phi$ 的公式 $A\phi = T^{-1}A\phi S$ ，看着和SVD分解有相似之处，它们之间是否有联系呢？
  2. 在像空间的图形里，像空间 $\text{im}(\phi)$ 包含了零空间么？如果是的话，那么秩 - 零化度定理...
- 展开 ∨

作者回复: 你好，那一刻，很好的问题。

1. 这个要从哪个角度去看了，如果通过SVD来求旋转矩阵，那么文中说的变换矩阵和SVD就有关系。
2. 像空间包含零空间，不管是核还是像，其实都是函数映射，所以我们不能从包含的关系去理解。

